

数字图形处理大作业

(高光谱遥感图像分割)

课程名称	数字图形处理
项目名称	高光谱遥感图像分割
专业班级	计算机技术
姓 名	孙熙春
学 号	182306057026

目录

遥感图像分割	- 1 -
前言:	- 1 -
1、基本思想	- 1 -
2、半监督残差梯形网络	- 3 -
3、噪声增强	- 4 -
4、 实验结果	- 5 -
5、 总结	- 7 -

高光谱遥感图像分割

前言：

本文基于深度残差网络与深度自编码网络综合的一种半监督残差梯型网络，通过比较不同局部特征增强方法的优劣，分析了高光谱遥感图像的噪声特点，并将最佳局部特征增强方法应用于 Semi-RLNet 中，优化模型评价标准，并对遥感图像分类后进行分割，划分出不同类别地物的信息，以便基于不同的地物信息进行更多操作。

1、基本思想

传统的半监督学习中主要是利用无标记数据对分类器作预训练，得到能够提取图像特征参数，然后通过有监督数据对参数微调使其最终用于图像分类中，这种方法的弊端在于使无监督训练学习与有监督学习分离，参数更新无法同步，导致分类器对两种数据的统计分析不均匀，并不是严格意义上的“半监督学习”，梯型网络由 Rasmus 等人在 2015 年提出，该模型能够同时利用有标记数据和无标记数据训练，在半监督学习领域取得了不俗的成绩。

传统梯型网络模型如图 1.1 所示，模型主要包含两个部分，最左侧的两列是基于全连接网络的自编码网络，用于无监督学习，最右边的一侧是全连接网络，用于监督学习，模型整体来看犹如几座梯子搭在一起，故得名梯型网络。




图 1.1 梯型网络结构图

梯型网络能够取得优异的图像分类性能主要有以下几个重要的特点：

(1) 梯型网络最基本的一点就是将无监督自编码网络与监督神经网络有机结合，可以同时通过无标记数据与有标记数据训练模型，缓解了标记样本少带来的图像特征提取不足的情况。

(2) 在模型的无监督学习部分采用了不同于传统降噪自编码的网络结构，其在传统降噪自编码网络的基础上，又对全连接网络的每一层提取的特征都加入了特征增强，并在编码和解码的过程中的每一层都加入一个跳转的连接 $g^{(x)}$ ，可以看成是降噪函数，这个特点允许降噪自编码专注于更高级别上的抽象特征，使得网络的高层特征可以表达出底层特征留下的一些细节。

(3) 梯型网络可以看成是一种嵌套的降噪自动编码网络的集合，最终通过损失函数 $C_d^{(x)}$ 将它们联系在一起。而无监督学习部分的损失函数也不再是原始数据与重建数据之间的“差别”，而是扩展到了特征与特征之间的“差别”，网络最终的损失函数由传统监督损失函数，以及无监督自编码损失函数，以及特征损失函数三者求和得到，这种共享更有助于降噪自动编码网络去学习降噪过程，因为它

在学习任务中又加入了一部分子特征的表达。

2、半监督残差梯形网络

仔细分析梯型网络模型的结构，我们可以发现：

首先，传统的半监督梯型网络是基于全连接网络设计的，网络层次较浅，容易导致对图像深层特征提取不足，虽然在文中也有基于深度 CNN 的网络结构，但是网络模型的搭建并没有固定的模式，如果单纯的增加网络层次，网络参数同样会急剧增加，导致模型过拟合，如何能在既保证网络深度的同时又不过多的增加网络训练的参数是值得思考的问题。

其次，传统的梯型网络与常规深度自编码网络不同的另一个特点是每一层在编码器和解码器之间都有一个跳转连接 $g^{(x)}$ ，目的是起到一定的降噪作用，但是在实际的应用中，通过训练梯型网络时便可以发现，这么做会导致训练时间大幅增加，影响图像分类的效率。

因此，针对传统梯型网络结构层次浅，无法很好的提取深层次抽象特征的问题，本文综合深度残差网络(ResNet)的优势，提出了一种基于深度残差网络的半监督残差梯型网络 Semi-RLNet，为了简化设计，模型依旧采用构建块组合的思想构建。

模型整体结构延续了传统梯型网络的结构，将全连接网络结构修改成了深度残差网络结构，模型依旧主要包含两个部分，左侧及中间的一系列共同组成了基于深度残差网络的无监督自编码网络结构，右侧为基于深度残差网络的监督网络结构。针对传统梯型训练时间较长，导致图像分类效率低的问题，Semi-RLNet 去除了传统的深度梯型网络里的降噪函数，该模型有效利用了残差网络的残差单元

优势，保证更深网络层次结构的同时，减少了参数的数量，因此能够利用更深层次的网络提取无标记样本与标记样本的潜在表达，这种表达相较于浅层全卷积网络更加能够表示原始图像的特征。

3、噪声增强

底层特征代表着图像最基本的特征如轮廓，边缘等，因此底层特征提取的好坏影响高层次特征的抽象表达。考虑到特征增强的特点以及降噪函数的作用，本章通过对网络模型的分析，在 Semi-RLNet 引入了局部特征增强方法，保证部分底层特征的鲁棒性，又能在一定程度上提高模型训练的效率。

不同的特征增强方式，会影响自编码网络对于特征提取的好坏，本文选取了四种特征增强方法：高斯噪声、均匀噪声、指数噪声以及高斯噪声。通过对比四种特征增强的在光谱图像上的实验分类结果，获得最优的特征增强方法，将其用于 Semi-RLNet 中。

在空间域与频域中，由于高斯噪声的易处理性，使得高斯噪声(也被称为正态噪声)模型经常被用于实践中，高斯随机变量 z 的概率密度函数由公式(3.1)给出：

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2} \quad (3.1)$$

其中 μ 和 σ 分别表示 x 的期望和标准差。

均匀噪声的概率密度由公式(3.2)给出：

$$p(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{其它} \end{cases} \quad (3.2)$$

指数噪声的概率密度由公式(3.3)给出：

$$p(x) = \begin{cases} \alpha e^{-\alpha x} & x \geq 0 \\ 0 & x < 0 \end{cases} \quad (3.3)$$

其中, $\alpha > 0$ 。

伽马噪声的概率密度由公式(3.4)给出:

$$p(x) = \begin{cases} \frac{a^b x^{b-1}}{(b-1)!} e^{-ax} & x \geq a \\ 0 & x < 0 \end{cases} \quad (3.4)$$

实际上, 指数分布的概率密度函数是当 $b=1$ 时伽马概率密度分布的特殊情况。

不同噪声的分布曲线如下图所示:




图 3.1 不同噪声概率密度函数图

4、实验结果

Pavia University 原图如 4.1 所示:



图 4.1 Pavia University 原图

对 Pavia University 数据集的不同地物进行分类，分类后在相同的坐标上画出不同的地物图像，以达到分割的目的，分割结果如图 4.2 所示：

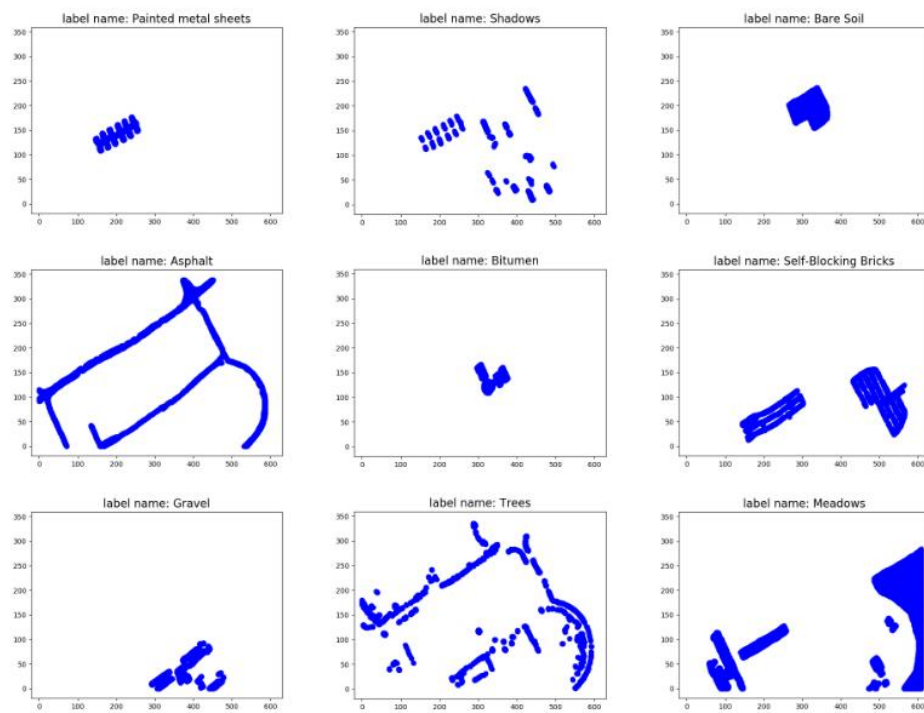


图 4.2 分割结果

5、 总结

本文在对梯型网络分析的基础上，利用了残差梯型网络 Semi-RLNet，针对梯型网络层次较浅的问题，Semi-RLNet 应用了可以加深层次又降低参数数量的深度残差神经网络-ResNet；同时考虑到梯型网络模型较为复杂，导致训练时间过长，Semi-RLNet 去除了编码与解码层之间的降噪函数，降低网络模型的复杂性，在一定程度上能减少模型训练的时间；通过实验对比了不同噪声增强方法的性能，并以此分析了高光谱遥感图像噪声的特点；将最优局部特征增强技术应用于 Semi-RLNet，给出了 Semi-RLNet 基本参数设置及详细的训练流程；最后通过实验对高光谱遥感图像的地物进行分类，并对地物信息进行分割，划分出不同的区域，可直观的找到需要的地物信息并进行更多操作。